

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Josip Ančić

**Generativna umjetna inteligencija u
sustavima obnovljivih izvora energije**

ZAVRŠNI RAD

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Josip Ančić

Matični broj: 0016166204

Studij: Informacijski i poslovni sustavi

**Generativna umjetna inteligencija u
sustavima obnovljivih izvora energije**

ZAVRŠNI RAD

Mentor/Mentorica:

Izv. prof. dr. sc. Dijana Oreški

Varaždin, rujan 2026.

Josip Ančić

Izjava o izvornosti

Izjavljujem da je moj završni rad izvorni rezultat mojeg rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autor je potvrdio prihvaćanjem odredbi u sustavu ELF FOI (Moodle)

Sažetak

U ovom završnom radu bavim se primjenom generativne umjetne inteligencije u sustavima obnovljivih izvora energije, prije svega u fotonaponskim sustavima. Njihova proizvodnja ovisi o vremenskim prilikama pa ju je teško unaprijed planirati, a o dobrim predviđanjima ovisi koliko će se sustavom pametno upravljati. U teorijskom dijelu rada objašnjavam kako rade četiri najvažnije obitelji generativnih modela i gdje se danas koriste u energetici. U praktičnom dijelu na stvarnim satnim mjerenjima kućanstva s fotonaponskim sustavom iz javno dostupnog skupa podataka Open Power System Data treniram uvjetni varijacijski autoenkoder koji generira scenarije dnevnih profila proizvodnje i potrošnje. Model na sezonski uravnoteženom testnom skupu daje točnije prognoze od dvaju jednostavnih referentnih modela, a generirani scenariji vjerno prate sezonske obrasce, čime pokazujem da generativni modeli mogu poslužiti kao podrška upravljanju kućnim fotonaponskim sustavima.

Ključne riječi: generativna umjetna inteligencija; strojno učenje; obnovljivi izvori energije; fotonaponski sustavi; predviđanje proizvodnje i potrošnje energije

Sadržaj

1. Uvod.....	1
2. Obnovljivi izvori energije i izazovi upravljanja	3
2.1. Fotonaponski sustavi	3
2.2. Varijabilnost proizvodnje i izazovi planiranja	3
3. Podaci	5
4. Generativna umjetna inteligencija.....	7
4.1. Diskriminativni i generativni modeli	7
4.2. Generativne suparničke mreže (GAN).....	7
4.3. Varijacijski autoenkoderi (VAE)	8
4.4. Difuzijski modeli	8
4.5. Transformeri i veliki jezični modeli	9
5. Primjene generativne umjetne inteligencije u sustavima obnovljivih izvora energije.....	10
5.1. Probabilistička prognoza proizvodnje i potrošnje.....	11
5.2. Generiranje scenarija	11
5.3. Sintetski podaci i proširenje skupova podataka	12
6. Metodologija	13
6.1. Priprema podataka i eksplorativna analiza	13
6.2. Uvjetni varijacijski autoenkoder	14
6.3. Referentni modeli i mjere vrednovanja	15
7. Rezultati	16
7.1. Točnost prognoze proizvodnje	16
7.2. Točnost prognoze potrošnje.....	17
7.3. Rasprava	18
8. Zaključak	20
Popis literature	21
Popis slika	23
Popis tablica.....	24
Izjava o korištenju alata generativne umjetne inteligencije.....	25

1. Uvod

Sve više kućanstava u Hrvatskoj i Europi ugrađuje solarne panele na svoje krovove. Time postaju mali proizvođači energije, ali nasljeđuju i problem koji velike elektrane muči odavno: koliko će paneli sutra proizvesti, ovisi o vremenu. Oblačan dan može prepoloviti proizvodnju, a o dobroj procjeni proizvodnje i potrošnje ovisi hoće li se energija potrošiti u pravo vrijeme, pohraniti ili predati u mrežu. Ahmed, Sreeram, Mishra i Arif (2020) u svom preglednom radu ističu da je upravo predviđanje proizvodnje postalo jedno od središnjih pitanja uklapanja solarnih sustava u elektroenergetsku mrežu. Rast broja malih proizvođača mijenja i način na koji mreža radi. Tokovi energije više nisu jednosmjerni, od velikih elektrana prema potrošačima, nego se struja u sunčano podne slijeva iz tisuća kućnih elektrana natrag u mrežu. Operatorima je zato sve teže održavati ravnotežu proizvodnje i potrošnje. Kućanstva, s druge strane, muči nešto sasvim praktično: kada uključiti perilicu, kada napuniti kućnu bateriju ili električni automobil da se vlastita energija što bolje iskoristi.

Oba pitanja, ono mrežno i ono kućansko, počinju istim korakom: treba unaprijed znati koliko će se energije proizvesti i potrošiti. Bez te procjene nema ni pametnog upravljanja. Problem je u tome što je proizvodnja vezana uz vrijeme, a potrošnja uz navike ukućana, pa se ni jedna ni druga ne daju opisati jednostavnom formulom.

Klasične metode planiranja često se oslanjaju na fiksne modele i ograničen broj podataka. U posljednjih nekoliko godina razvija se drugačiji pristup: generativna umjetna inteligencija. Riječ je o modelima koji iz povijesnih podataka nauče kako podaci izgledaju pa mogu stvarati nove, realistične primjere. Koliko je to područje živo pokazuje sistematski pregled koji su proveli Cali i sur. (2026): od 106 analiziranih studija o generativnim modelima u energetici, velika većina objavljena je u posljednjih nekoliko godina. Za predviđanje je ta ideja zanimljiva iz jednostavnog razloga. Običan model prognoze vrati jednu brojku, recimo da će sustav sutra proizvesti 30 kWh. Generativni model umjesto toga može vratiti stotinu mogućih sutrašnjica, od tmurne do savršeno sunčane, zajedno s informacijom koliko je koja vjerojatna. Takav skup scenarija korisniji je za odlučivanje jer opisuje i neizvjesnost, a ne samo očekivanje. Danas se u tu svrhu koriste četiri velike obitelji modela: generativne suparničke mreže, varijacijski autoenkoderi, difuzijski modeli i transformeri. Da pristup nije samo teorija, pokazuju konkretni radovi. Chen, Wang, Kirschen i Zhang (2018) GAN-om su generirali realistične dnevne profile proizvodnje sunca i vjetra izravno iz mjerenja, bez pretpostavki o njihovoj razdiobi. Dumas, Wehenkel, Lanaspèze, Cornélusse i Sutura (2022) generativnim su modelima izrađivali dnevne prognoze proizvodnje i potrošnje dovoljno kvalitetne za trgovanje energijom na burzi.


Cilj ovog rada je istražiti primjenu generativnih modela na podacima stvarnog kućanstva s fotonaponskim sustavom. Pritom me vode tri pitanja. Prvo, mogu li generativni modeli iz povijesnih mjerenja naučiti dnevne i sezonske obrasce proizvodnje i potrošnje? Drugo, kakvu prognozu daju u usporedbi s jednostavnim referentnim modelima? I treće, koliko su generirani scenariji statistički vjerni stvarnim podacima? Analizu provodim na javno dostupnom skupu podataka *Household Data* platforme Open Power System Data, koji sadrži višegodišnja satna mjerenja proizvodnje i potrošnje europskih kućanstava, a podatke detaljno opisujem u trećem poglavlju. Za obradu podataka i izgradnju modela koristim Python, a literaturu navodim prema APA stilu, u skladu s FOI preporukama za citiranje i referenciranje.

2. Obnovljivi izvori energije i izazovi upravljanja

Prije nego što prijedem na podatke i modele, korisno je razumjeti što se u fotonaponskom sustavu uopće mjeri i zašto je proizvodnju teško predvidjeti.

2.1. Fotonaponski sustavi

Fotonaponski (engl. *photovoltaic*, PV) sustav pretvara Sunčevo zračenje izravno u električnu energiju. Srce sustava su fotonaponski moduli na krovu, a uz njih dolaze izmjenjivač (engl. *inverter*), koji istosmjernu struju iz modula pretvara u izmjeničnu kakvu koriste kućanski uređaji, i pametno brojilo koje bilježi razmjenu energije s mrežom. Snaga sustava izražava se u kilovatima vršne snage (kWp), no koliko će sustav stvarno proizvesti ovisi o ozračenju, temperaturi, orijentaciji i nagibu krova te zasjenjenju. Za kućanstvo je posebno važan odnos proizvodnje i potrošnje. Energiju koju sustav proizvede i kućanstvo odmah potroši naziva se samopotrošnjom; višak odlazi u mrežu, a manjak se iz mreže kupuje. Budući da je vlastita energija u pravilu isplativija od kupljene, korisno je što više potrošnje preseliti u sate kada sustav proizvodi. A za to treba unaprijed znati koliko će se proizvesti.



Slika 1: Fotonaponski sustav na krovu obiteljske kuće (Izvor: *Fotonaponski sustav*, bez dat.)

Na slici 1 je prikazan jedan primjer fotonaponskog sustava koji pretvara Sunčevu energiju u električnu. Zelena kutija označena na slici je izmjenjivač koji istosmjernu struju pretvara u izmjeničnu kako bi mogla biti korištena od strane kućanskih aparata.

2.2. Varijabilnost proizvodnje i izazovi planiranja

Proizvodnja se mijenja na više vremenskih razina. Unutar dana prati kretanje Sunca, među danima ovisi o naoblaci, a kroz godinu o duljini dana i visini Sunca. Najveći problem su nagle promjene: prolazak oblaka može u nekoliko minuta srušiti izlaznu snagu na trećinu.

Metode predviđanja proizvodnje razvijaju se desetljećima, od fizikalnih i statističkih modela do dubokog učenja. Opsežan pregled tog područja dali su Ahmed i sur. (2020), koji zaključuju da metode dubokog učenja u pravilu daju najtočnije prognoze, ali upozoravaju i da jedna brojka često nije dovoljna. Sve se više traži probabilistička prognoza, koja opisuje i koliko je ta prognoza pouzdana. Tu na scenu stupaju generativni modeli, jer oni po svojoj prirodi uče cijelu razdiobu podataka, a ne samo prosjek.

3. Podaci

Prije modeliranja treba dobro upoznati podatke. U tome se vodim metodologijom CRISP-DM (engl. *Cross-Industry Standard Process for Data Mining*), koju su Chapman i sur. (2000) opisali kao standardni proces rada s podacima u šest faza: razumijevanje problema, razumijevanje podataka, priprema podataka, modeliranje, evaluacija i primjena. Ovu sam metodologiju koristio na više kolegija, pa se njome vodim i ovdje. Ovo poglavlje pokriva fazu razumijevanja podataka, a priprema i modeliranje slijede u nastavku rada. Koristim javno dostupan skup podataka *Household Data* platforme Open Power System Data (OPSD, 2020), nastao u sklopu europskog projekta CoSSMic. Skup sadrži mjerenja potrošnje i proizvodnje energije za jedanaest objekata u njemačkoj regiji Konstanz: šest kućanstava, tri industrijska i dva javna objekta. Podaci su objavljeni pod otvorenom licencom i mogu se slobodno koristiti uz navođenje izvora, te sam ih zato i odabrao za ovaj rad. Satna inačica skupa jedna je CSV datoteka od 38 454 retka i 71 stupca, s mjerenjima od 11. prosinca 2014. do 1. svibnja 2019. Prva dva stupca su vremenske oznake, u UTC-u (engl. Coordinated Universal Time) i lokalnom vremenu, posljednji stupac bilježi koje su vrijednosti u retku interpolirane, a preostalih 68 stupaca su brojčana mjerenja pojedinih objekata. Svako mjerenje zapisano je kao kumulativno stanje brojila u kWh, dakle kao broj koji samo raste, pa se satna energija dobiva oduzimanjem uzastopnih očitavanja. Objekti nisu mjereni jednako dugo, što se vidi po različitom broju popunjenih zapisa po stupcima.

Tablica 1 donosi popis svih stupaca s brojem popunjenih zapisa i opisom sadržaja. Uz osnovna mjerenja, proizvodnju te preuzimanje i predaju energije, neka kućanstva imaju i mjerenja pojedinačnih trošila, poput perilice rublja, hladnjaka ili dizalice topline, a kućanstvo residential4 čak i punjenje električnog vozila. Za nastavak rada najzanimljivija su kućanstva koja istodobno imaju proizvodnju i oba smjera razmjene s mrežom, dakle residential3, residential4 i residential6, jer se za njih iz mjerenja može izračunati i ukupna potrošnja.

Tablica 1: Popis stupaca skupa podataka Household Data (autorski rad prema OPSD, 2020)

Stupac	Broj zapisa	Opis
utc_timestamp	38454	vremenska oznaka (UTC)
cet_cest_timestamp	38454	lokalna vremenska oznaka (CET/CEST)
DE_KN_industrial1_grid_import	16434	industrial1: energija preuzeta iz mreže
DE_KN_industrial1_pv_1	17288	industrial1: proizvodnja FN sustava (niz 1)
DE_KN_industrial1_pv_2	17288	industrial1: proizvodnja FN sustava (niz 2)
DE_KN_industrial2_grid_import	11279	industrial2: energija preuzeta iz mreže
DE_KN_industrial2_pv	12000	industrial2: proizvodnja FN sustava
DE_KN_industrial2_storage_charge	9754	industrial2: punjenje baterijskog spremnika
DE_KN_industrial2_storage_decharge	9754	industrial2: pražnjenje baterijskog spremnika
DE_KN_industrial3_area_offices	14360	industrial3: potrošnja uredskog prostora
DE_KN_industrial3_area_room_1	14360	industrial3: potrošnja prostorije 1
DE_KN_industrial3_area_room_2	14360	industrial3: potrošnja prostorije 2
DE_KN_industrial3_area_room_3	14361	industrial3: potrošnja prostorije 3

DE_KN_industrial3_area_room_4	14361	industrial3: potrošnja prostorije 4
DE_KN_industrial3_compressor	14360	industrial3: kompresor
DE_KN_industrial3_cooling_aggregate	14360	industrial3: rashladni agregat
DE_KN_industrial3_cooling_pumps	14360	industrial3: rashladne pumpe
DE_KN_industrial3_dishwasher	14361	industrial3: perilica posuđa
DE_KN_industrial3_ev	10430	industrial3: punjenje električnog vozila
DE_KN_industrial3_grid_import	11510	industrial3: energija preuzeta iz mreže
DE_KN_industrial3_machine_1	14360	industrial3: stroj 1
DE_KN_industrial3_machine_2	14360	industrial3: stroj 2
DE_KN_industrial3_machine_3	14360	industrial3: stroj 3
DE_KN_industrial3_machine_4	14361	industrial3: stroj 4
DE_KN_industrial3_machine_5	14361	industrial3: stroj 5
DE_KN_industrial3_pv_facade	14360	industrial3: proizvodnja FN sustava (fasada)
DE_KN_industrial3_pv_roof	14360	industrial3: proizvodnja FN sustava (krov)
DE_KN_industrial3_refrigerator	14247	industrial3: hladnjak
DE_KN_industrial3_ventilation	14360	industrial3: ventilacija
DE_KN_public1_grid_import	4550	public1: energija preuzeta iz mreže
DE_KN_public2_grid_import	1124	public2: energija preuzeta iz mreže
DE_KN_residential1_dishwasher	15845	residential1: perilica posuđa
DE_KN_residential1_freezer	12896	residential1: zamrzivač
DE_KN_residential1_grid_import	15873	residential1: energija preuzeta iz mreže
DE_KN_residential1_heat_pump	15873	residential1: dizalica topline
DE_KN_residential1_pv	15873	residential1: proizvodnja FN sustava
DE_KN_residential1_washing_machine	15846	residential1: perilica rublja
DE_KN_residential2_circulation_pump	19823	residential2: cirkulacijska pumpa
DE_KN_residential2_dishwasher	19134	residential2: perilica posuđa
DE_KN_residential2_freezer	10251	residential2: zamrzivač
DE_KN_residential2_grid_import	15798	residential2: energija preuzeta iz mreže
DE_KN_residential2_washing_machine	24733	residential2: perilica rublja
DE_KN_residential3_circulation_pump	33210	residential3: cirkulacijska pumpa
DE_KN_residential3_dishwasher	29097	residential3: perilica posuđa
DE_KN_residential3_freezer	28732	residential3: zamrzivač
DE_KN_residential3_grid_export	22555	residential3: energija predana u mrežu
DE_KN_residential3_grid_import	11904	residential3: energija preuzeta iz mreže
DE_KN_residential3_pv	22555	residential3: proizvodnja FN sustava
DE_KN_residential3_refrigerator	25101	residential3: hladnjak
DE_KN_residential3_washing_machine	30546	residential3: perilica rublja
DE_KN_residential4_dishwasher	12620	residential4: perilica posuđa
DE_KN_residential4_ev	20288	residential4: punjenje električnog vozila
DE_KN_residential4_freezer	20288	residential4: zamrzivač
DE_KN_residential4_grid_export	20360	residential4: energija predana u mrežu
DE_KN_residential4_grid_import	20360	residential4: energija preuzeta iz mreže
DE_KN_residential4_heat_pump	12311	residential4: dizalica topline
DE_KN_residential4_pv	20360	residential4: proizvodnja FN sustava
DE_KN_residential4_refrigerator	10764	residential4: hladnjak
DE_KN_residential4_washing_machine	12258	residential4: perilica rublja
DE_KN_residential5_dishwasher	23541	residential5: perilica posuđa
DE_KN_residential5_grid_import	30804	residential5: energija preuzeta iz mreže
DE_KN_residential5_refrigerator	14564	residential5: hladnjak
DE_KN_residential5_washing_machine	23541	residential5: perilica rublja
DE_KN_residential6_circulation_pump	21534	residential6: cirkulacijska pumpa
DE_KN_residential6_dishwasher	14061	residential6: perilica posuđa
DE_KN_residential6_freezer	15346	residential6: zamrzivač
DE_KN_residential6_grid_export	16690	residential6: energija predana u mrežu
DE_KN_residential6_grid_import	21534	residential6: energija preuzeta iz mreže
DE_KN_residential6_pv	21534	residential6: proizvodnja FN sustava
DE_KN_residential6_washing_machine	14784	residential6: perilica rublja
interpolated	31797	oznaka interpoliranih vrijednosti u retku

4. Generativna umjetna inteligencija


U ovom poglavlju prolazim kroz četiri obitelji generativnih modela koje se danas najčešće koriste: generativne suparničke mreže, varijacijske autoenkodere, difuzijske modele i transformere.

4.1. Diskriminativni i generativni modeli

Razliku između diskriminativnih i generativnih modela najlakše je objasniti na primjeru. Diskriminativni model uči granicu između klasa, recimo hoće li na slici prepoznati mačku ili psa. Generativni model ide korak dalje: on uči kako slike mačaka izgledaju pa može stvoriti novu mačku koja nikad nije postojala. Prevedeno u kontekst ovog rada, generativni model može stvoriti dnevnu krivulju proizvodnje kakva nikada nije izmjerena, ali izgleda kao da jest. Upravo to svojstvo koristi se za generiranje scenarija i procjenu neizvjesnosti. Ukratko, diskriminativni modeli prepoznaju i razvrstavaju podatke postavljanjem jasne granice između klasa, dok generativni modeli uče samu strukturu podataka kako bi na temelju nje mogli stvarati potpuno novi sadržaj.

4.2. Generativne suparničke mreže (GAN)

Generativne suparničke mreže (engl. *Generative Adversarial Networks*, GAN) predstavili su Goodfellow i sur. (2014). Ideja je jednostavna i pomalo duhovita: dvije neuronske mreže igraju igru jedna protiv druge. Generator iz slučajnog šuma stvara lažne primjere, a diskriminator pokušava razlikovati stvarne od izmišljenih. Kako trening odmiče, generator postaje sve bolji u varanju, sve dok njegovi primjeri ne postanu gotovo neodvojivi od stvarnih. GAN-ovi imaju i svoje mane. Trening je nestabilan i osjetljiv na postavke, a poznat je i kolaps modova (engl. *mode collapse*), kada generator nauči proizvoditi samo dio raznolikosti podataka. Unatoč tome, prema pregledu koji su proveli Cali i sur. (2026), GAN-ovi su i dalje najzastupljenija generativna arhitektura u energetske primjenama.




Slika 2: Shema generativne suparničke mreže (Izvor: GeeksforGeeks, bez dat.)

GAN-ove je najlakše zamisliti kao dvije osobe koje imaju svoj zadatak. Jednoj je zadatak napraviti lažne slike koje izgledaju skoro isto kao original, a druga strana treba učiti i prepoznati koje slike su kopije, a koje original. Iako su GAN-ovi u energetske primjenama najzastupljeniji, u ovom radu nisam ih odabrao. Razlog je praktičan: treniranje dviju mreža koje se natječu osjetljivo je na postavke i sklonu kolapsu modova, a cilj mi je bio model koji se može stabilno istrenirati na skromnom skupu od nekoliko stotina dana i implementirati od nule.

4.3. Varijacijski autoenkoderi (VAE)

Varijacijski autoenkoder (engl. *Variational Autoencoder*, VAE), koji su predložili Kingma i Welling (2014), radi na drugačijem principu. Enkoder sažima ulazni primjer u nekoliko brojeva, u takozvani latentni prostor, a dekode iz tih brojeva pokušava rekonstruirati original. Trik je u tome što se latentni prostor tijekom treninga uređuje tako da se iz njega mogu izvlačiti i novi, slučajni primjeri. VAE se trenira stabilnije od GAN-a, ali za to plaća cijenu: generirani primjeri znaju biti zaglađeni, odnosno manje raznoliki od stvarnih podataka. S tim će se svojstvom susresti i u praktičnom dijelu rada.




Slika 3: Shema varijacijskog autoenkodera (Izvor: Great Learning, 2020)

Svi elementi s ove sheme pojavljuju se i u mojoj implementaciji: enkoder sažima dnevni profil od 24 vrijednosti u latentni prostor od osam brojeva, a dekoder iz njega rekonstruira profil. Upravo mogućnost uzorkovanja iz latentnog prostora omogućuje generiranje scenarija opisano u poglavlju 6.

4.4. Difuzijski modeli

Difuzijski modeli najmlađa su od četiri obitelji. Njihovu praktičnu vrijednost pokazali su Ho, Jain i Abbeel (2020): stvarnim se podacima kroz velik broj malih koraka dodaje šum dok od njih ne ostane samo šum, a model uči obrnuti put, kako iz šuma korak po korak vratiti podatak. Danas su difuzijski modeli standard u generiranju slika, a Li i sur. (2025) pokazuju da dobro rade i na vremenskim nizovima proizvodnje energije.




Slika 4: Postupno dodavanje šuma i obrnuti postupak uklanjanja šuma (Izvor: Vahdat i Kreis, 2022)

Prikaz je namjerno napravljen na stvarnom prosječnom lipanjskom profilu iz korištenog skupa podataka, a ne na slici, kako bi se vidjelo da isti postupak vrijedi i za energetske vremenske nizove. Model bi učio obrnuti smjer, od šuma prema profilu, i tako stvarao nove dnevne krivulje.

4.5. Transformeri i veliki jezični modeli

Transformer, arhitektura koju su uveli Vaswani i sur. (2017), temelji se na mehanizmu pažnje (engl. *attention*): model za svaki element niza uči na koje se druge dijelove niza treba osloniti. Za razliku od starijih rekurentnih mreža, transformer cijeli niz obrađuje odjednom, pa se na njemu mogu trenirati vrlo veliki modeli. Najpoznatiji primjer su veliki jezični modeli (engl. *Large Language Models*, LLM) poput ChatGPT-a. Kako navode Cali i sur. (2026), u energetici se LLM-ovi zasad koriste opreznije, primjerice za analizu dokumentacije i pomoć operaterima, ali njihov udio brzo raste.



Slika 5: Od transformera do velikog jezičnog modela (Izvor: Do Minh, 2025)

U ovom radu transformer ne koristim, no navodim ga jer čini osnovu alata koji se danas najčešće povezuju s pojmom generativne umjetne inteligencije, pa i onih spomenutih u izjavi na kraju rada.

5. Primjene generativne umjetne inteligencije u sustavima obnovljivih izvora energije

Zhang, Glaws, Cortiella, Emami i King (2025) pregledali su gotovo dvjesto radova o generativnim modelima u energetici i podijelili ih u nekoliko skupina. Za ovaj rad najvažnije su tri: probabilistička prognoza, generiranje scenarija i stvaranje sintetskih podataka.

5.1. Probabilistička prognoza proizvodnje i potrošnje

Kod probabilističke prognoze model umjesto jedne brojke daje raspon mogućih ishoda. Dobar primjer je istraživanje koje su proveli Dumas i sur. (2022): na zadatku dnevne prognoze proizvodnje fotonaponskih sustava, vjetroelektrana i potrošnje usporedili su normalizirajuće tokove, GAN-ove i VAE te pokazali da sve tri obitelji mogu proizvesti scenarije dovoljno kvalitetne za stvarne poslovne odluke, poput trgovanja energijom na burzi.




Slika 6: Ilustracija probabilističke prognoze (autorski rad)

Razlika između jedne prognozirane vrijednosti i razdiobe mogućih ishoda ključna je za ovaj rad: upravo raspon koji shema prikazuje pokušavam dobiti generiranjem scenarija.

5.2. Generiranje scenarija

Generirati scenarije znači stvoriti velik broj mogućih sutrašnjica koje zajedno opisuju neizvjesnost proizvodnje. Prekretnicu su napravili Chen i sur. (2018) kada su pokazali da GAN može naučiti generirati realistične dnevne profile proizvodnje sunca i vjetra izravno iz podataka, bez ikakvih pretpostavki o njihovoj razdiobi. Njihov rad postao je polazna točka za velik dio kasnijih istraživanja. Noviji radovi u istu svrhu sve češće koriste difuzijske modele; Li

i sur. (2025), primjerice, difuzijskim modelom uspješno hvataju i sezonske obrasce i kratkotrajne oscilacije proizvodnje.



Slika 7: Ilustracija generiranja scenarija (autorski rad)

Svaka putanja na shemi odgovara jednom mogućem sutrašnjem danu. U ovom radu takvih putanja generiram dvjesto po danu, a njihov prosjek koristim kao točkastu prognozu.

5.3. Sintetski podaci i proširenje skupova podataka

Treća skupina primjena rješava čest problem iz prakse: mjerenja je premalo, na primjer kod tek izgrađene elektrane. Yoon, Jarrett i van der Schaar (2019) za tu su svrhu razvili TimeGAN, model koji uz suparničko učenje čuva i vremensku dinamiku nizova. Sintetski podaci koriste se za proširenje skupova za treniranje, za testiranje sustava, ali i za dijeljenje podataka bez otkrivanja privatnih navika kućanstava.



Slika 8: Ilustracija sintetskih podataka (autorski rad)

Ovu primjenu nisam koristio jer mi je razdoblje mjerenja bilo dovoljno dugo, no ona je zanimljiva za nove elektrane, gdje povijesnih podataka za treniranje još nema.

6. Metodologija

U ovom poglavlju opisujem kako sam podatke pripremio za modeliranje, kako je građen generativni model te kako vrednujem njegove rezultate. Time pokrivam faze pripreme podataka i modeliranja CRISP-DM procesa.


6.1. Priprema podataka i eksplorativna analiza

Budući da su mjerenja kumulativna, satne vrijednosti energije dobio sam oduzimanjem uzastopnih očitavanja. Pritom sam naišao na probleme tipične za stvarne podatke: negativne razlike i fizikalno nemoguće skokove zbog ispada opreme, koje sam uklonio, te rupe u mjerenjima. Dane s manje od 22 sata valjanih podataka izbacio sam iz analize, čime je ostalo 835 potpunih dana, od kojih 819 ima i potpuni prethodni dan potreban modelu. Zbog velikih sezonskih razlika u obrascima dane ne dijelim kronološki: po uzoru na Dumas i sur. (2022), unutar svakoga kalendarskog mjeseca 75% dana nasumično odlazi u skup za treniranje, a 25% u skup za testiranje, pa su sve sezone zastupljene u oba skupa. Skup za treniranje tako ima 615 dana, a skup za testiranje 204 dana koje model tijekom učenja nije vidio. Osnovnu statistiku pripremljenih podataka daje tablica 2.


Tablica 2: Opisna statistika dnevnih vrijednosti kućanstva residential4 (autorski rad)

Veličina (dnevno, kWh)	Prosjek	Std. dev.	Min.	Maks.
Proizvodnja PV	29,09	19,36	0,06	68,07
Potrošnja	18,66	10,57	3,96	55,06
Preuzeto iz mreže	12,00	9,71	1,53	43,48
Predano u mrežu	22,43	18,68	0,00	63,89

Slika 9 dobro pokazuje glavni izazov: ljeti sustav proizvodi i do pet puta više nego zimi, dok je potrošnja najveća upravo zimi. Prosječni dnevni profili na slici 10 otkrivaju i drugi obrazac. Proizvodnja ima zvonolik oblik s vrhom oko podneva, a potrošnja jutarnji i večernji vrh, zimi znatno izraženiji. Udio samopotrošnje u promatranom razdoblju iznosi 22,9%.



Slika 9: Mjesečna proizvodnja i potrošnja kućanstva residential4 (autorski rad)



Slika 10: Prosječni dnevni profili proizvodnje i potrošnje po sezonama (autorski rad)

Razlika između zvonolikog profila proizvodnje i dvovršne krivulje potrošnje objašnjava zašto sam za obje veličine trenirao odvojene modele umjesto jednog zajedničkog.

6.2. Uvjetni varijacijski autoenkoder

Za glavni model odabrao sam uvjetni varijacijski autoenkoder (engl. conditional Variational Autoencoder, cVAE). VAE sam opisao u poglavlju 4.3; a uvjetni znači da modelu uz profil dajem i dodatne informacije, u ovom slučaju mjesec u godini, ukupnu energiju prethodnog dana i oznaku vikenda, pa model uči kako profili izgledaju u pojedinim uvjetima. Ulaz je dnevni profil od 24 satne vrijednosti, latentni prostor ima osam dimenzija, a enkoder i dekoder po jedan skriveni sloj sa 64 neurona. Model sam implementirao od nule u NumPyju, uključujući i vlastitu izvedbu algoritma propagacije pogreške unatrag, i trenirali ga 3000 epoha

Adam optimizatorom u minigrupama od 64 primjera. Pokazalo se da je najvažnija postavka težina KL člana u funkciji gubitka: s uobičajenom vrijednošću $\beta = 1$ model je davao točne prognoze, ali gotovo identične scenarije. Smanjenjem težine na $\beta = 0,1$ raznolikost scenarija približila se stvarnoj, a točnost je ostala praktički ista. Za proizvodnju i potrošnju treniram odvojene modele.

6.3. Referentni modeli i mjere vrednovanja

Uz cVAE koristim dva jednostavna referentna modela: klimatologiju, tj. prosječni profil istoga mjeseca izračunat na skupu za treniranje, i persistenciju, koja sutrašnji dan predviđa jučerašnjim profilom. Točkastu prognozu cVAE-a računam kao prosjek 200 generiranih scenarija. Točnost prognoza mjerim srednjom apsolutnom pogreškom (MAE) i korijenom srednje kvadratne pogreške (RMSE) po satu, na testnom razdoblju. Za ocjenu kvalitete scenarija uspoređujem prosječne profile i razdiobe dnevnih suma stvarnih i generiranih podataka. Dobar generativni model mora pogoditi statistička svojstva podataka, a ne samo imati malu pogrešku prognoze.

7. Rezultati

U ovom poglavlju prikazujem rezultate: najprije točnost točkaste prognoze u odnosu na referentne modele, zatim kvalitetu generiranih scenarija, a na kraju raspravu o tome što rezultati znače i koja su ograničenja rada.


7.1. Točnost prognoze proizvodnje

Pokazatelji pogreške sažeti su u tablici 3. Za proizvodnju cVAE ima najmanju pogrešku po objema mjerama: MAE 0,515 i RMSE 1,021 kWh/h. Prednost pred klimatologijom je mala, oko 2% po RMSE-u, što je i očekivano: sezonski uravnotežena podjela ide na ruku upravo klimatologiji, jer se prosjek svakoga mjeseca računa iz svih raspoloživih godina. Persistencija je uvjerljivo najlošija, s RMSE-om lošijim za više od 20%: kad se vrijeme naglo promijeni, jučerašnji profil potpuno promaši, a takve velike pogreške RMSE najviše kažnjava.


Tablica 3: Pokazatelji pogreške točkaste prognoze na testnom skupu (autorski rad)

Serija	Model	MAE (kWh/h)	RMSE (kWh/h)
Proizvodnja PV	cVAE	0,515	1,021
Proizvodnja PV	Klimatologija	0,542	1,038
Proizvodnja PV	Persistencija	0,560	1,296
Potrošnja	cVAE	0,347	0,540
Potrošnja	Klimatologija	0,348	0,544
Potrošnja	Persistencija	0,401	0,699

Kvalitetu scenarija prikazuju slike 11 i 12. Generirani scenariji dobro prate stvarne prosječne profile u oba godišnja doba: u lipnju se poklapanje vidi i u razdiobi dnevne proizvodnje (slika 12), a u siječnju model prosjek blago precjenjuje, 11,3 prema stvarnih 9,9 kWh po danu, uz nešto manju raznolikost od stvarne. Primjere pojedinačnih prognoza na testnim danima donosi slika 13.



Slika 11: Generirani scenariji proizvodnje za siječanj i lipanj (autorski rad)




Slika 12: Razdioba dnevne proizvodnje: stvarni lipanjski dani i cVAE scenariji (autorski rad)

Preklapanje dvaju histograma pokazuje da model ne pogađa samo prosjek, nego i raspon lipanjskih dana, uključujući slabije i vrlo sunčane. Blaga razlika u širini razdiobe posljedica je zaglađivanja o kojem pišem u raspravi.

7.2. Točnost prognoze potrošnje

I kod potrošnje je cVAE najbolji po objema mjerama, s MAE-om 0,347 i RMSE-om 0,540 kWh/h, premda mu je klimatologija ovdje vrlo blizu, dok persistencija zaostaje za više od 20% (tablica 3). Satna potrošnja ovisi o ponašanju ukućana, pa pojedinačne skokove, na

primjer uključivanje pećnice, ne pogađa nijedan model. Ono što cVAE dobro hvata jest prosječni dnevni ritam kućanstva, s jutarnjim i večernjim vrhom, što se vidi na slici 13 desno.



Slika 13: Primjeri prognoze na testnim danima (autorski rad)

Lijevi primjer pokazuje granicu modela: naglo popodnevno smanjenje proizvodnje zbog naoblake ne može se predvidjeti bez meteoroloških podataka. Desni primjer pokazuje ono što model dobro hvata, opći dnevni ritam potrošnje s jutarnjim i večernjim vrhom.

7.3. Rasprava

Prednost generativnog pristupa nije u samoj brojci pogreške. Razlika prema klimatologiji je mala, oko dva posto po RMSE-u, ali uz prognozu dobivam i scenarije koji opisuju neizvjesnost, a toga kod klimatologije i persistencije nema. Do sličnog zaključka dolaze i Dumas i sur. (2022). Klimatologija je ovdje jak protivnik iz jednostavnog razloga: promatram jedno kućanstvo bez meteoroloških podataka, pa najveći dio onoga što se o sutrašnjem danu uopće može znati leži u godišnjem dobu, a tu informaciju klimatologija koristi u potpunosti. Ostatak razlike među danima istog mjeseca određuje naoblaka, koju bez vremenske prognoze ne može pogoditi nijedan model. Moj model o njoj ima samo posrednu naznaku, energiju prethodnog dana, jer se lijepo i loše vrijeme obično zadrže po nekoliko dana. Ahmed i sur. (2020) meteorološke ulaze navode kao ključan čimbenik točnosti, pa bi s njima razlika gotovo sigurno bila veća. Scenariji su korisni upravo tamo gdje jedna brojka nije dovoljna. Ako sustav upravljanja kućanstvom raspolaže sa sto mogućih sutrašnjica, može procijeniti i vjerojatnost da proizvodnja padne ispod neke granice, pa umjesto pravila „upali perilicu u podne” postaviti pravilo „upali perilicu kada barem osamdeset posto scenarija predviđa dovoljan višak energije”. To je odluka pod nesigurnošću i zato se generativni modeli u energetici uopće koriste (Zhang i sur., 2025). Tijekom rada dvije su me postavke iznenadile koliko utječu na rezultat. Prva je

podjela podataka: u kronološkoj podjeli model je zimu u treningu vidio premalo puta i zimski su scenariji bili izrazito podcijenjeni, a nakon stratificirane podjele po mjesecima dobro prate stvarne vrijednosti. Druga je težina KL člana. S uobičajenom vrijednošću $\beta = 1$ prognoze su bile uredne, ali su scenariji ispali gotovo istovjetni, pa uži od stvarnog raspona; sa $\beta = 0,1$ raznolikost se približila stvarnoj uz nepromijenjenu točnost, dok je daljnje snižavanje počelo kvariti prognozu. Kod sezonskih podataka to očito nisu tehnički detalji, nego dio metodologije. Ograničenja treba iznijeti otvoreno. Blaga sklonost zaglađivanju scenarija ostaje, jer je raznolikost lipanjskih scenarija nešto manja od stvarne, što je poznato svojstvo varijacijskih autoenkodera opisano u poglavlju 4.3; difuzijski modeli bolje hvataju rubove razdiobe pa bi tu vjerojatno bili bolji izbor (Li i sur., 2025). Model je testiran na jednom kućanstvu i na razdoblju s dvije zime i dva ljeta, pa su rijetki vremenski uvjeti slabo zastupljeni, a prognozira cijeli dan unaprijed na satnoj razini i nije prikladan za odluke koje traže reakciju u nekoliko minuta. Nastavak rada vidim u tri koraka: uključivanju meteorološke prognoze među uvjetne varijable, što bi najviše podiglo točnost, zamjeni modela difuzijskim te provjeri na kućanstvima residential3 i residential6, koja su već u korištenom skupu podataka.

8. Zaključak

U radu sam prošao put od teorije do primjene. Objasnio sam kako rade četiri glavne obitelji generativnih modela i gdje se koriste u energetici, a zatim sam na dvogodišnjim mjeranjima kućanstva s fotonaponskim sustavom trenirao uvjetni varijacijski autoenkoder za predviđanje dnevnih profila proizvodnje i potrošnje. Najviše me vremena, suprotno očekivanju, odnijela faza prije modeliranja. Prvotna je zamisao bila raditi na podacima stvarnih elektrana iz okolice, no aplikacija za nadzor tih sustava na razini pristupa kojom sam raspolagao nije nudila izvoz mjerenja, pa sam nakon nekoliko pokušaja odustao i prešao na javno dostupan skup podataka. Ni tu posao nije bio gotov odabirom skupa: od jedanaest objekata samo je nekolicina imala istodobno mjerenje proizvodnje i oba smjera razmjene s mrežom, a bez toga se potrošnja ne može izračunati. Mjerenja su k tome zapisana kao kumulativna stanja brojlara, pa sam satne vrijednosti dobio tek nakon diferenciranja, uklanjanja negativnih razlika nastalih ispadima opreme i izbacivanja nepotpunih dana. Od gotovo 39 000 zapisa na kraju je ostalo 835 upotrebljivih dana.

Izrada samog modela donijela je dvije stvari koje nisam predvidio. Prva je bila podjela podataka: kada sam dane podijelio kronološki, model je zimu u treningu vidio premalo puta i zimski su scenariji ispali izrazito podcijenjeni. Tek nakon prelaska na nasumičnu podjelu stratificiranu po mjesecima, koju sam preuzeo od Dumasa i suradnika, scenariji su počeli pratiti stvarne vrijednosti u svim godišnjim dobima. Druga je bila težina KL člana u funkciji gubitka. S uobičajenom vrijednošću $\beta = 1$ model je davao uredne prognoze, ali gotovo istovjetne scenarije, što je za ovaj rad bilo neupotrebljivo; nakon niza pokušaja zaustavio sam se na $\beta = 0,1$, gdje je raznolikost scenarija bliska stvarnoj, a točnost praktički nepromijenjena. Zahtjevno je bilo i samo pisanje modela u NumPyju, jer su gradijenti kroz reparametrizacijski trik izvedeni ručno, pa je svaka pogreška u izvodu značila da model uči vrlo sporo ili nikako.

Na sezonski uravnoteženom testnom skupu od 204 dana model je nadmašio oba referentna modela po objema mjerama pogreške, s RMSE-om 1,021 kWh/h za proizvodnju i 0,540 kWh/h za potrošnju. Generirani scenariji vjerno prate sezonske obrasce, a ljeti se njihova razdioba gotovo poklapa sa stvarnom. Time sam odgovorio na tri pitanja iz uvoda: generativni modeli mogu naučiti dnevne i sezonske obrasce proizvodnje i potrošnje kućanstva, po točnosti su bolji od jednostavnih referentnih modela, a generirani scenariji statistički su vjerni stvarnim podacima.

Rad ima i jasne granice. Testiran je na jednom kućanstvu i razdoblju koje obuhvaća samo dvije zime, model ne koristi meteorološku prognozu, a prognozira cijeli dan unaprijed na satnoj razini. Kao nastavak vidim tri koraka: uključivanje meteoroloških podataka među uvjetne

varijable, zamjenu varijacijskog autoenkodera difuzijskim modelom i provjeru na više kućanstava. Ono što mi je iz cijelog procesa ostalo najkorisnije jest spoznaja da kod ovakvih podataka odluke o pripremi i podjeli skupa utječu na rezultat jednako koliko i sam odabir modela.

Popis literature

- Ahmed, R., Sreeram, V., Mishra, Y., & Arif, M. D. (2020). A review and evaluation of the state-of-the-art in PV solar power forecasting: Techniques and optimization. *Renewable and Sustainable Energy Reviews*, 124, 109792. <https://doi.org/10.1016/j.rser.2020.109792>
- Anthropic. (2026). *Claude* [Veliki jezični model]. <https://claude.ai/>
- Cali, U., Halden, U., Andoni, M., Catak, F. O., Chen, S., Couraud, B., ... Flynn, D. (2026). Generative AI and LLM applications in renewable energy and smart grids: A systematic review for the sustainable energy transition. *Artificial Intelligence Review*, 59(7), 153. <https://doi.org/10.1007/s10462-026-11545-2>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.
- Chen, Y., Wang, Y., Kirschen, D. S., & Zhang, B. (2018). Model-free renewable scenario generation using generative adversarial networks. *IEEE Transactions on Power Systems*, 33(3), 3265-3275. <https://doi.org/10.1109/TPWRS.2018.2794541>
- Do Minh, T. (2025). *Generative AI – Part 3: The architecture behind GenAI* [Slika]. NashTech Blog. Preuzeto 3.9.2026. s <https://blog.nashtechglobal.com/generative-ai-part-3-the-architecture-behind-genai/>
- Dumas, J., Wehenkel, A., Lanaspéze, D., Cornélusse, B., & Suter, A. (2022). A deep generative model for probabilistic energy forecasting in power systems: Normalizing flows. *Applied Energy*, 305, 117871. <https://doi.org/10.1016/j.apenergy.2021.117871>
- Fotonaponski sustav [Slika]. (bez dat.). Solar Projekt. Preuzeto 3.9.2026. s <https://solarprojekt.hr/wp-content/uploads/2014/06/b1-1.jpg>
- GeeksforGeeks. (bez dat.). *Generative adversarial network (GAN)* [Slika]. Preuzeto 3.9.2026. s <https://www.geeksforgeeks.org/>
- Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... Bengio, Y. (2014). Generative adversarial nets. U *Advances in Neural Information Processing Systems 27 (NIPS 2014)* (str. 2672-2680). Curran Associates.
- Great Learning. (2020). *Variational autoencoder* [Slika]. Preuzeto 3.9.2026. s <https://www.mygreatlearning.com/blog/understanding-variational-autoencoders/>
- Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. U *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)* (str. 6840-6851). Curran Associates.

- Kingma, D. P., & Welling, M. (2014). Auto-encoding variational Bayes. U *2nd International Conference on Learning Representations (ICLR 2014)*.
<https://doi.org/10.48550/arXiv.1312.6114>
- Li, D., Zhao, X., Xu, W., Ge, C., Li, C., Liu, W., & Ma, D. (2025). A novel renewable energy scenario generation method based on multi-resolution denoising diffusion probabilistic models. *Energies*, 18(14), 3781. <https://doi.org/10.3390/en18143781>
- Open Power System Data [OPSD]. (2020). *Data package Household Data* (verzija 2020-04-15). https://doi.org/10.25832/household_data/2020-04-15
- Sveučilište u Zagrebu, Fakultet organizacije i informatike [SUZG FOI]. (2026). *Smjernice za korištenje umjetne inteligencije u nastavi i studentskim radovima*.
https://www.foi.unizg.hr/sites/default/files/smjernice_za_koristenje_umjetne_inteligencije_u_nastavi_i_studentskim_radovima_suzg_foi.pdf
- Vahdat, A., i Kreis, K. (2022). *Improving diffusion models as an alternative to GANs, Part 1* [Slika]. NVIDIA Technical Blog. Preuzeto 3.9.2026. s
<https://developer.nvidia.com/blog/improving-diffusion-models-as-an-alternative-to-gans-part-1/>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. U *Advances in Neural Information Processing Systems 30 (NIPS 2017)* (str. 5998-6008). Curran Associates.
- Yoon, J., Jarrett, D., & van der Schaar, M. (2019). Time-series generative adversarial networks. U *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)* (str. 5508-5518). Curran Associates.
- Zhang, X., Glaws, A., Cortiella, A., Emami, P., & King, R. (2025). Deep generative models in energy system applications: Review, challenges, and future directions. *Applied Energy*, 380, 125059. <https://doi.org/10.1016/j.apenergy.2024.125059>

Popis slika

Slika 1: Fotonaponski sustav na krovu obiteljske kuće (Izvor: Fotonaponski sustav, bez dat.)	3
Slika 2: Shema generativne suparničke mreže (Izvor: GeeksforGeeks, bez dat.)	8
Slika 3: Shema varijacijskog autoenkodera (Izvor: Great Learning, 2020)	8
Slika 4: Postupno dodavanje šuma i obrnuti postupak uklanjanja šuma (Izvor: Vahdat i Kreis, 2022)	9
Slika 5: Od transformera do velikog jezičnog modela (Izvor: Do Minh, 2025)	10
Slika 6: Ilustracija probabilističke prognoze (autorski rad)	11
Slika 7: Ilustracija generiranja scenarija (autorski rad)	12
Slika 8: Ilustracija sintetskih podataka (autorski rad)	12
Slika 9: Mjesečna proizvodnja i potrošnja kućanstva residential4 (autorski rad)	14
Slika 10: Prosječni dnevni profili proizvodnje i potrošnje po sezonama (autorski rad)	14
Slika 11: Generirani scenariji proizvodnje za siječanj i lipanj (autorski rad)	17
Slika 12: Razdioba dnevne proizvodnje: stvarni lipanjski dani i cVAE scenariji (autorski rad)	17
Slika 13: Primjeri prognoze na testnim danima (autorski rad)	18

Popis tablica

Tablica 1: Popis stupaca skupa podataka Household Data (autorski rad prema OPSD, 2020)
5

Tablica 2: Opisna statistika dnevnih vrijednosti kućanstva residential4 (autorski rad)..... 13

Tablica 3: Pokazatelji pogreške točkaste prognoze na testnom skupu (autorski rad).....16

Izjava o korištenju alata generativne umjetne inteligencije

Pri izradi ovog rada korišteni su alati generativne umjetne inteligencije, u skladu sa *Smjernicama za korištenje umjetne inteligencije u nastavi i studentskim radovima* Fakulteta organizacije i informatike (SUZG FOI, 2026). Korišten je alat Claude tvrtke Anthropic, i to na sljedeće načine:

- rasprava o mogućim pristupima analizi i pomoć pri oblikovanju strukture rada;
- jezična i stilaska dorada teksta
- rješavanje logičkih problema unutar programskog koda

te je korišten alat Litmaps za:

- pretraživanje i predlaganje znanstvene literature te provjera bibliografskih podataka, pri čemu sam svaku referencu samostalno provjerio u izvorniku.

Konačan odabir izvora, metodologija, interpretacija rezultata i zaključci rada rezultat su mogjeg samostalnog rada. Sve tvrdnje preuzete iz literature provjerene su u izvornim radovima, a programski kod pokrenut je i provjeren u vlastitom okruženju. Izjavljujem da sam alate generativne umjetne inteligencije koristio odgovorno i transparentno te da preuzimam punu odgovornost za sadržaj ovog rada.

Josip Ančić